

第十九屆旺宏科學獎

創意說明書

參賽編號：SA19-226

作品名稱：綠繡眼鳴叫聲之機器學習與其探討

姓名：洪軾凱

關鍵字：鳥類鳴叫聲、機器學習、聲音分析

摘要

為了想分辨鳥類在不同生理時期是否會有不同特徵之鳴叫聲，決定希望藉由類神經網路得到解答。以綠繡眼為例，資料集中除了其鳴叫聲外，還觀察其行為分成巢前期、築巢期、抱卵期、巢外育、產蛋期、育雛期、雛失敗七種時期。經過分類、分段及 MFCC 轉換後，使用 Convolution Module 做為基底，各自接上 LSTM、GRU 及 Attention 作為模型訓練出不同結果，最終得到 Attention 能夠得到約 95% 之正確率，且藉由 Confusion Matrix 及 t-SNE 降維視覺化，能再進一步證明不同生理時期之鳴叫聲確實有不同特徵。除了可以將模型優化，將資料集加入不同雜訊模擬不同情況外，希望未來可以應用於比較各種鳥類於不同時期鳴叫聲，並尋找不同種類之間之相似度，藉此驗證不同鳥類之間的親緣關係。

壹、研究動機

記得小二時有次，整班被苑惠老師神秘的趕到走廊外，不知情的被帶到學校的某個角落，分享她在校內發現的領角鴟（*Otus bakkamoena*, 鷦鵣科角鴟屬）。雖然當時領角鴟眼睛睜大大的，但完全無動於衷（之後才知道他其實是在睡覺）。我和同學都對此覺得有趣，也因為這件事情，有一段時間很常和死黨們跑到那裡附近玩耍，玩累了就會邊看著他睡覺邊聊天。

某天一如往常我們賽跑到那棵樹下，但非常神奇的，我們第一次聽到領角鴟的鳴叫聲；「嗚——嗚——嗚——」雖然老師曾經說如果聽到牠的叫聲一定要馬上告訴她，但我們就只是呆呆的站在樹下聽他嗚嗚叫，甚至希望他和我們說話。希望某天可以再聽到牠發出不一樣的聲音，不過沒過幾天他就消失在校園了。



圖 1、領角鴟（學名：*Otus bakkamoena*）[1]

自此之後，每當聽到鳥鳴時，會想聽懂到底不同的鳴叫聲有沒有不同的意義。但總是沒有辦法靠自己聽出一些端倪，只能在盛夏午休的睡夢中被反覆的鳴叫聲吵醒，卻不知道他想要表達什麼。直到高中，因緣際會下再次碰觸到這個領域，決定不再拘泥於讓自己聽得懂，而是將這個重責大任交付給演算法，希望可以明確證明鳥的鳴叫聲確實會因為不同的原因而有不同特徵。

貳、研究目的

- 一、驗證綠繡眼會在不同生理時期會有不同特徵之鳴叫聲。
- 二、嘗試利用類神經網路辨識不同生理時期下叫聲之特性。
- 三、發現不同的類神經網路架構下其精準度和效率之差異。

參、研究方法

一、研究設備

1. 本機：MacBook Pro (Retina, 15-inch, Mid 2015)
2. 線上資源：TAIWANIA 2
 - (1) Intel Xeon Gold CPU
 - (2) Nvidia Tesla T100 w/32GB



圖 2、台灣杉二號[2]

3. 虛擬環境

TensorFlow, NumPy, Matplotlib, Wave, Pydub, Glob, Librosa 等。

# Name	Version
_libgcc_mutex	0.1
ca-certificates	2020.1.1
certifi	2020.4.5.1
ld_impl_linux-64	2.33.1
libedit	3.1.20181209
libffi	3.2.1
libgcc-ng	9.1.0
libstdc++-ng	9.1.0
ncurses	6.2
openssl	1.1.1g
pip	20.0.2
python	3.7.7
readline	8.0
setuptools	46.1.3
sqlite	3.31.1
tk	8.6.8
wheel	0.34.2
xz	5.2.5
zlib	1.2.11

圖 3、於 Taiwania2 上 Conda 環境上安裝之套件

二、資料處理

1. 梅爾倒頻譜係（Mel-scale Frequency Cepstral Coefficients, MFCC）

因本次處理之資料多半為較短暫的聲音檔案，因希望從音檔中提取出特徵，於是選擇使用梅爾倒頻譜（Mel-Frequency Cepstrum, MFC）轉換，轉換方式如下：

- (1) 將訊號進行短時距傅立葉變換(Short-time Fourier transform)，得到 Spectrogram。

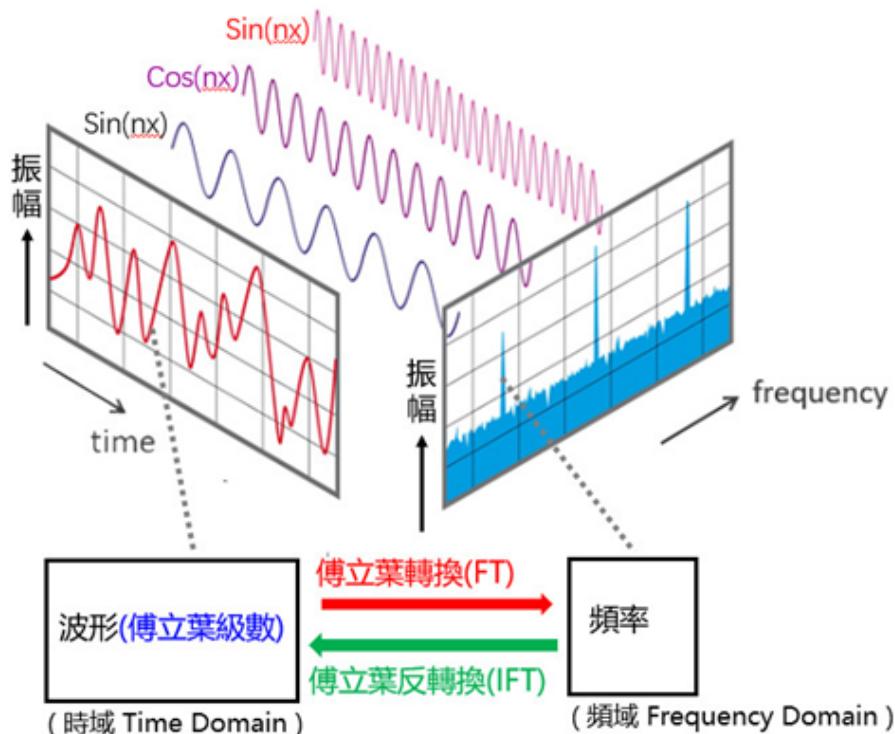


圖 4、傅立葉轉換示意圖，將音檔轉換為各頻率對強度的陣列。

- (2) 將頻譜映射 (mapping) 至梅爾刻度。
- (3) 取對數後取離散餘弦轉換 (discrete cosine transform) 得到 MFCC。

2. Adam Optimizer

訓練模型時為了讓模型在越短的時間找到最佳的做法(也就是找到適當的學習率任模型適當地被訓練好)，需要針對不同的模型使用梯度下降法才能達到最高效率。本次使用的梯度下降法利用 Adam 優化器，是利用兩種不同的優化器結合後的優化方法：

(1) AdaGard Optimizer

此種優化器根據梯度的不同情況蓋變學習率 (η) 的大小。在 AdaGrad Optimizer 中， η 乘上 $1/\sqrt{(n+\epsilon)}$ 再做參數更新，出現了一個 n 的參數，n 為前面所有梯度值的平方和，利用前面學習的梯度值平方和來調整學習率。

$$\begin{aligned}
W &\leftarrow W - \eta \frac{1}{\sqrt{n + \epsilon}} \frac{\partial L}{\partial W} \\
n &= \sum_{r=1}^t \left(\frac{\partial L_r}{\partial W_r} \right)^2 \\
W &\leftarrow W - \eta \frac{1}{\sqrt{\sum_{r=1}^t \left(\frac{\partial L_r}{\partial W_r} \right)^2 + \epsilon}} \frac{\partial L}{\partial W}
\end{aligned} \tag{1}$$

經由此種優化器可以達到以下效果：在訓練前期梯度比較小的時候，因為 n 較小，故能放大學習率，學習速度也會比較快。因為前期較不需要微調，因此可以將效率提高；當後期梯度較大的時候， n 也會較大，能夠約束學習率，讓學習速度降低並提高精確度，得到較高的 Accuracy。

(2) Momentum Optimizer

此種訓練方法可以想像成大球從高處往低處滾的感覺，當 loss 值（比喻成斜率）改變巨大時，更新率就會變大；當 loss 值改變變小時，更新率就會變小。但此更新率會參照之前斜率得出更新率。

$$\begin{aligned}
V_t &\leftarrow \beta V_{t-1} - \eta \frac{\partial L}{\partial W} \\
W &\leftarrow W + V_t
\end{aligned} \tag{2}$$

綜合以上，Adam 保留了 Momentum 對過去梯度的方向做梯度速度調整與 Adam 對過去梯度的平方值做 learning rate 的調整，再加上 Adam 有參數的「偏離校正」，使每一次的學習率都會有個確定的範圍，會讓參數的更新較為平穩。

$$\begin{aligned}
m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \frac{\partial L_t}{\partial W_t} \\
v_t &= \beta_2 v_{t-1} + (1 - \beta_2) \left(\frac{\partial L_t}{\partial W_t} \right)^2
\end{aligned} \tag{3}$$

$$\begin{aligned}
\hat{m}_t &= \frac{m_t}{1 - \beta_1^t} \\
\hat{v}_t &= \frac{v_t}{1 - \beta_2^t}
\end{aligned} \tag{4}$$

$$W \leftarrow W - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \tag{5}$$

肆、研究過程

一、文獻分析

1. 綠繡眼簡介

綠繡眼 (*Zosterops japonicus*)，雀形目繡眼科，目前分佈於大部分之東亞地區如中國、台灣、日本、南韓、北韓、越南、菲律賓等，且因為適應力強也曾因國際性鳥類貿易出現於世界各地。全台低至中海拔區域普遍可見，通常以 20~50 為單位成群出現。綠繡眼於台灣因其外表及叫聲又有暗綠繡眼鳥、青笛仔等俗名。

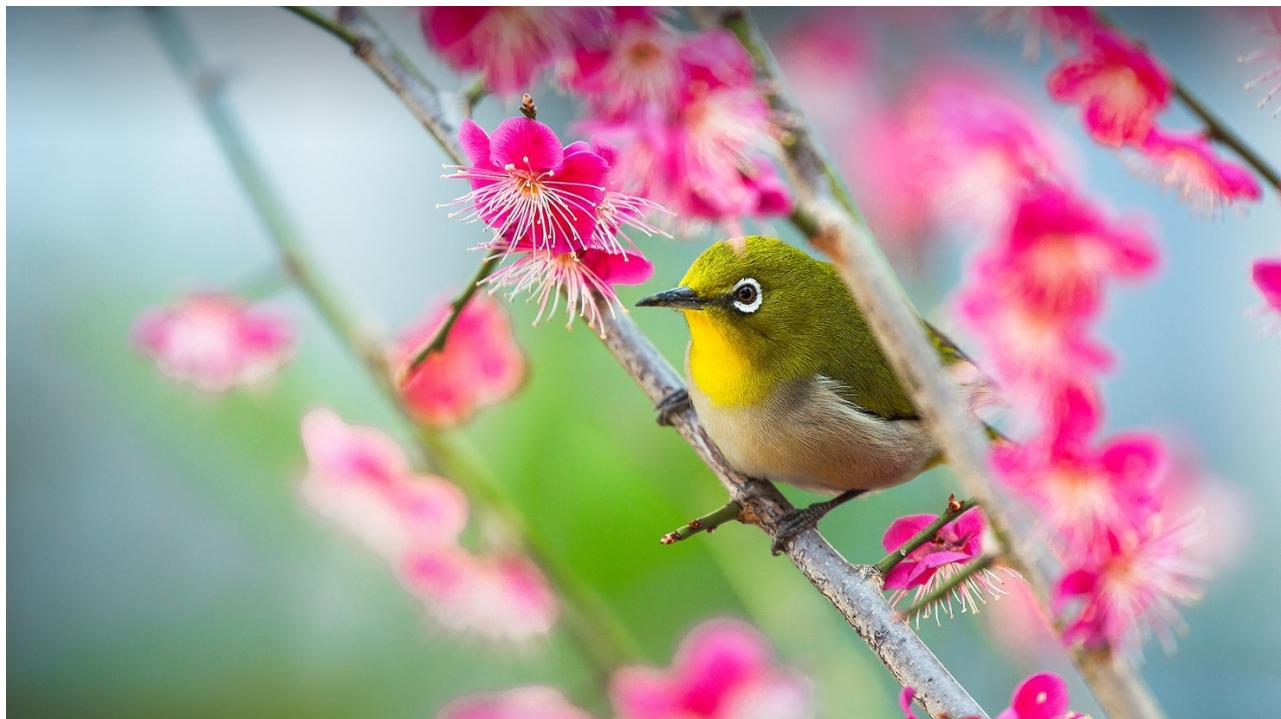


圖 5、綠繡眼（學名：*Zosterops japonicus*）[3]

選擇綠繡眼之主要原因，除了依照現有資料相較容易取得之外，綠繡眼同時也是台灣非常常見的鳥類之一。希望藉由綠繡眼的聲音資料來建立基本架構，並將其模型應用到辨識其他鳥類不同時期，甚至是辨識不同種類鳥類身上。

二、取得資料及預處理

1. 取得資料

本次資料集均為綠繡眼之鳴叫聲，而每一筆資料各有標記錄音時間、錄音地點、當時天氣、鳴叫長度、起鳴止鳴點、各生殖階段及當時錄音者留下來之備註。為了得到鳴叫聲與綠繡眼該時間之狀態，於是將重點放於生殖階段：

- (1) 巢前期：目標於巢前鳴叫之時期。
- (2) 築巢期：目標築巢之時期。
- (3) 抱卵期：目標抱卵之時期。

- (4) 巢外育：目標於巢外育養幼鳥時之時期。
- (5) 產蛋期：目標產蛋時鳴叫之時期，目標僅限於雌性。
- (6) 育雛期：目標育養幼鳥時鳴叫之時期，目標非指幼鳥。
- (7) 雛失敗：目標育養之幼鳥去世後鳴叫之時期。

因原始資料龐大無法一一呈現，故僅將前五個檔案呈現，並附上前 13 秒之波形圖與頻譜圖。經筆者反覆觀察，無法用肉眼觀察不同時期之關聯性及聲音之明顯差別（後續資料將置於後方附件）。

在約壓縮檔約為 3GB 之資料集中總共出現七隻綠繡眼，每一隻都有經歷過不同的時期。總共在約 30 個不同地點錄音，錄音時間集中在 1999 年至 2001 年。在約六小時之資料中將空白及噪音片段刪除後，可以得到約 30 分鐘的資料。

表 1、前五筆原始資料之預覽

日期	天氣	鳴者	生殖階段	波形圖
2001/4/3	陰 時雨	右 B.W 左 O	抱卵期	
2001/4/6	晴	右 BW 左 O	抱卵期	
2001/4/9	陰	右 BW 左 O	育雛期	
2001/5/28	雲	右 BW 左 O	育雛期	

2001/4/10	晴	右 BL 左 R	巢前期	
-----------	---	----------	-----	--

2. 聲音預處理

為了將資料集統一化，將所有資料篩選出有聲音之部分，長度切為以 300 timesteps 為一個原始檔，七個時期共得到 558 個原始檔。隨後進行 MFCC 轉換，得到每種時期的 NumPy 檔以便進行後續模型訓練。

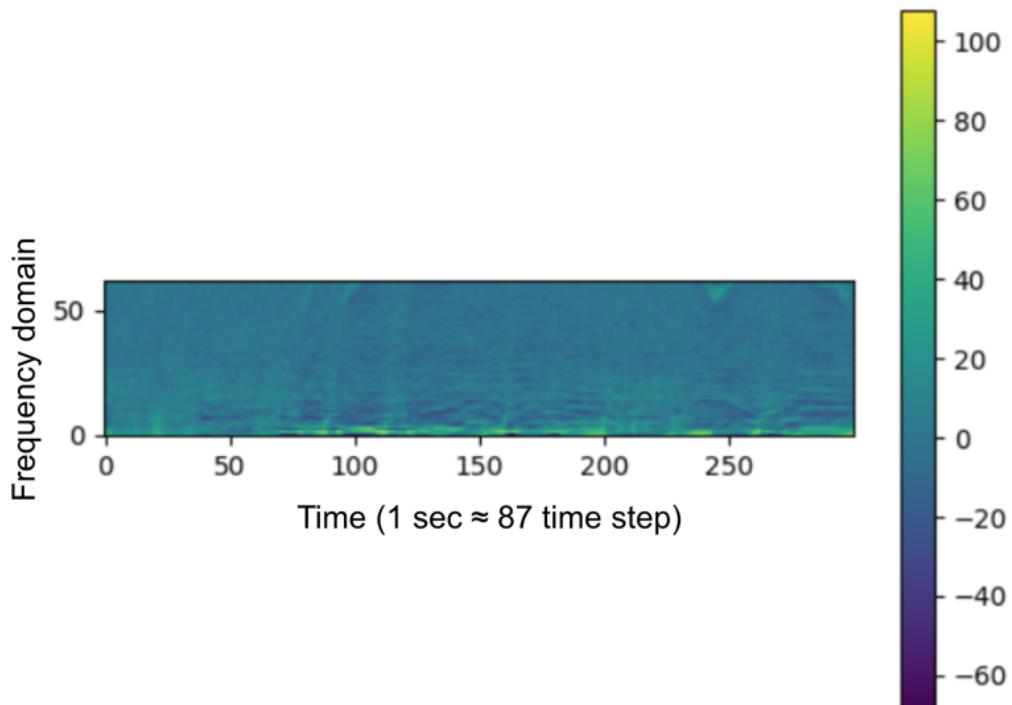


圖 6、經 MFCC 轉換後之結果

三、模型建構

1. TweetNet 模型建立

因考慮到訓練資料集太小及訓練的特性，決定自己開發出基本的模型。以下為實驗模型的基本概念：

為了在不影響視野且能夠有效降低 Overfitting 之可能性，使用 Convolution Module (因為使用全連接層會使用到太多參數，加上資料集太小避免 Overfitting 而不使用) 將模型擴大至 (Timestep, Frequency, 16) 之三維矩陣。

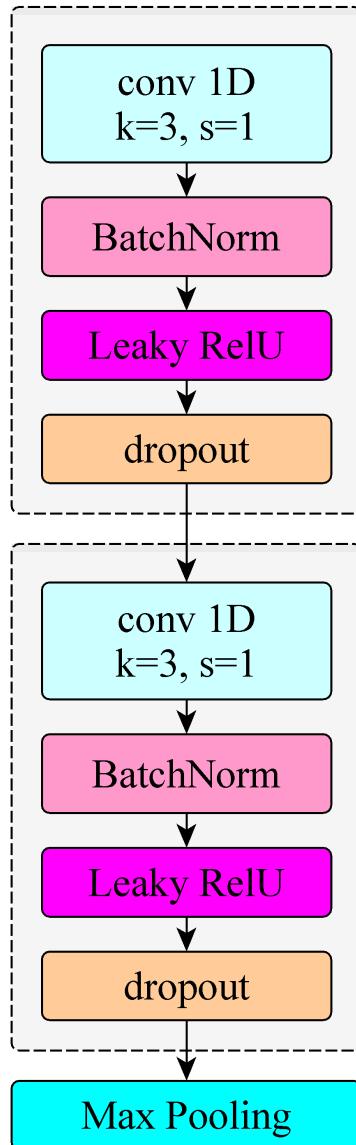


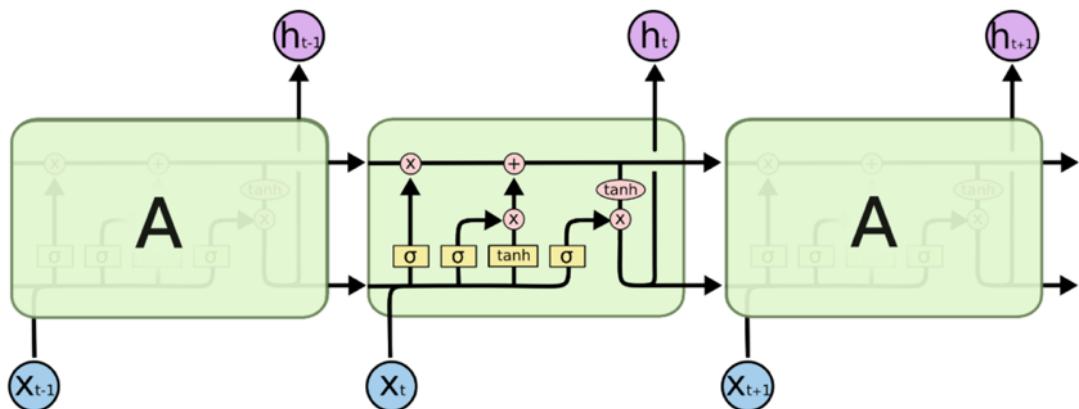
圖 7、Convolution Module 單元示意圖

對其進行 Convolution Module 後的 Model 經過數層最大池化層（Max pooling），汲取各特徵，最後在經過平均池化層（Average pooling）對四層剩餘的 Frequency domain 平均化，得到只剩下 Timestep 和各 channel 的陣列。

以此兩點為基礎，以下將提供三種不同方式連接全連接層及平均池化層。

2. Long Short-Term Memory

一開始想到可以當作模型的發法為遞歸神經網路（Recurrent Neural Network, RNN），但因為 RNN 在處理有時序性（資料的先後互相有關係稱為時序性）的資料時，會因為較無法繼承長期記憶而導致表現不佳，於是選擇長短期記憶模型（Long Short-Term Memory, LSTM）加入模型。



The repeating module in an LSTM contains four interacting layers.

圖 8、LSTM 單元結構圖

- (1) 對於每一筆輸入，形狀為 (time step, freq, channels=1)
- (2) 在每個 time step 上做一維卷積以及 Max Pooling，減少 Freq 並增加 Channel
- (3) 在每個時間點平均池化，得到形狀 (time step, 1, channels=64, 128)
- (4) 接上 LSTM，只輸出最後結果
- (5) 輸出 (全連接層)

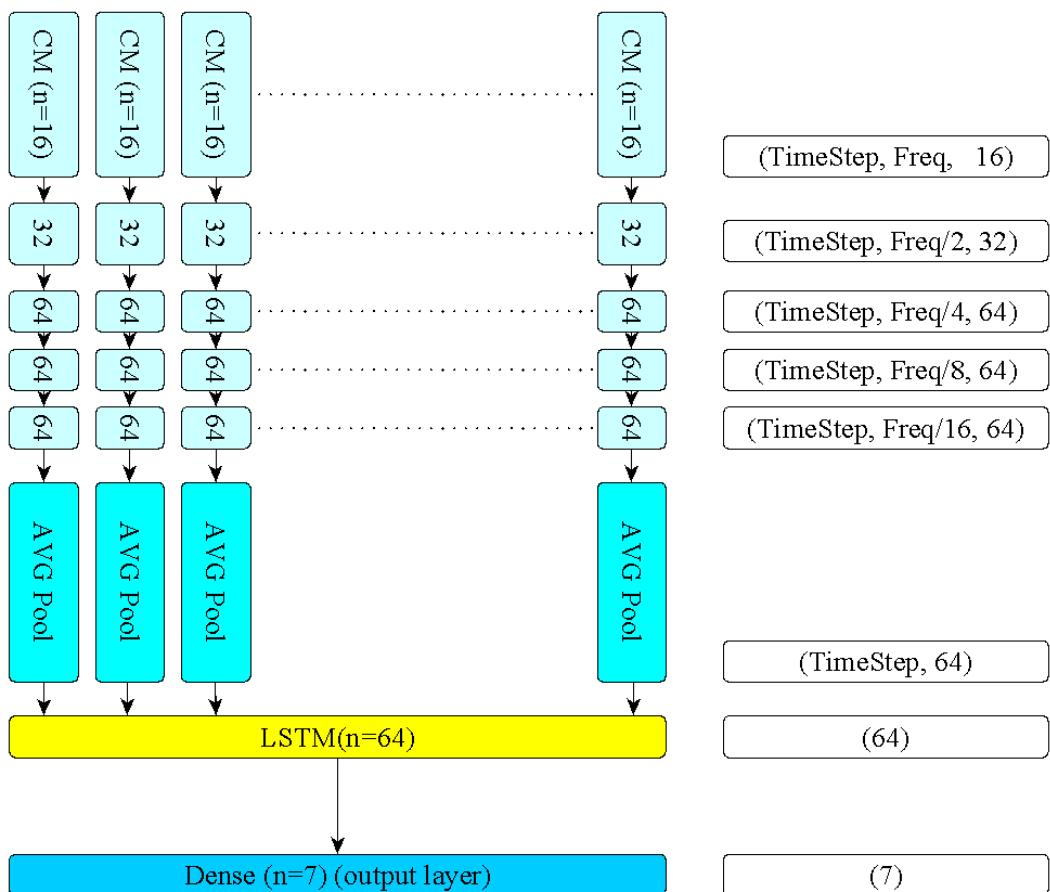


圖 9、以 LSTM 為底之模型架構圖

訓練資料與測試資料均為 6:4，Dropout rate 均為 0.5。嘗試使用 64 個 unit 及 128 個 unit 進行訓練，結果如下：

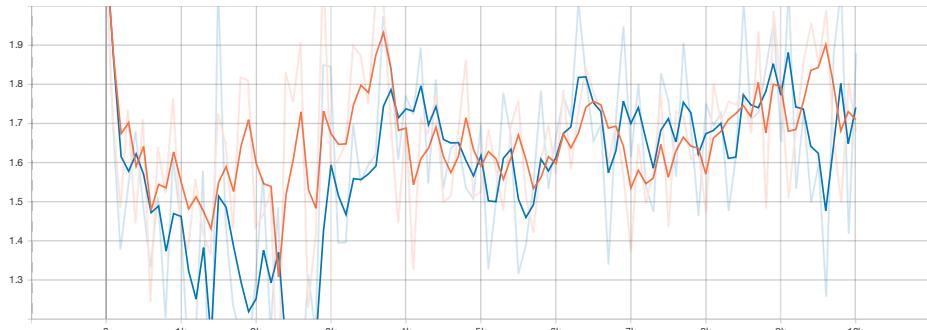


圖 10 (a)、 $n=64$ 時之 Loss 變化（橘色：測試資料；藍色：訓練資料）

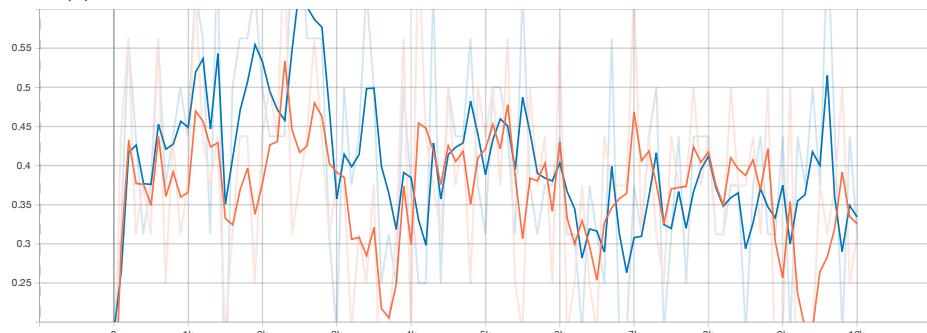


圖 10 (b)、 $n=64$ 時之 Accuracy 變化（橘色：測試資料；藍色：訓練資料）

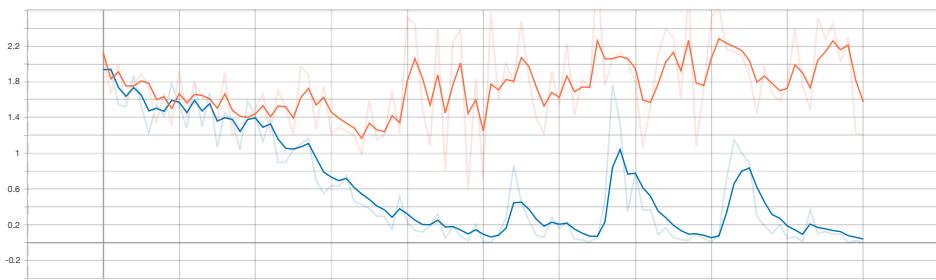


圖 11 (a)、 $n=128$ 時之 Loss 變化（橘色：測試資料；藍色：訓練資料）

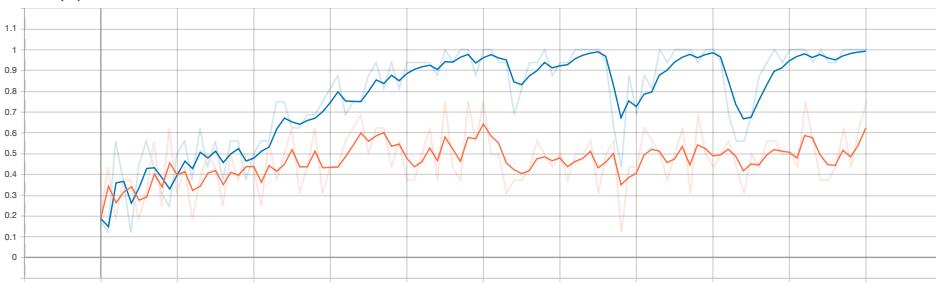


圖 11 (b)、 $n=128$ 時之 Accuracy 變化（橘色：測試資料；藍色：訓練資料）

$n=64$ 之最高 Accuracy 為 49.20049%， $n=128$ 時最高 Accuracy 則為 56.08856%。由實驗結果可以發現，當 $n=64$ 時會因為 node 太少而收斂效果不好 (Underfitting)；當 $n=128$ 時 Overfitting 的情況也很嚴重。因此使用下一種訓練模型。

3. Gated Recurrent Unit

此為 LSTM 的一種改良版。GRU 將 LSTM 中的遺忘閥 (forget gate) 與輸入閥 (input gate) 用一個更新閥 (update gate) 取代，並把單元狀態 (cell state) 和隱藏狀態 (H_t) 進行合併，計算新資訊的方式和 LSTM 也有所不同。

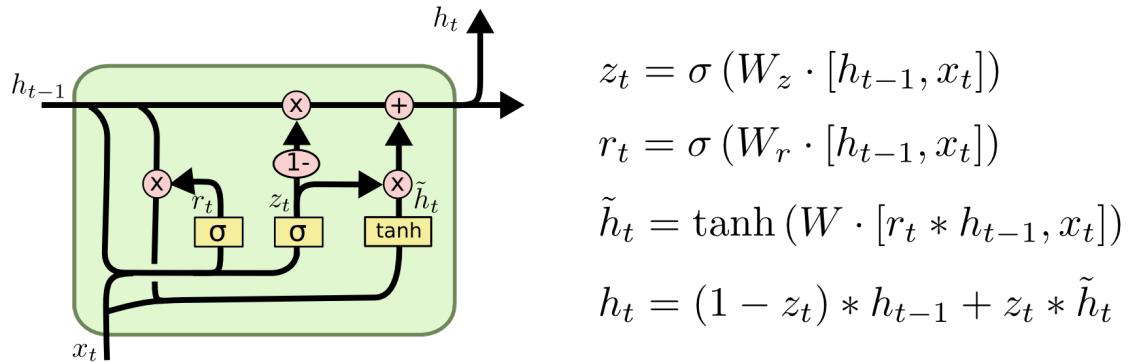


圖 12、GRU 單元結構圖及計算方式

- (1) 對於每一筆輸入，形狀為 (time step, freq, channels=1)
- (2) 在每個 time step 上做一維卷積以及 Max Pooling，減少 Freq 並增加 Channel
- (3) 在每個時間點平均池化，得到形狀 (time step, 1, channels=128)
- (4) 接上 GRU，只輸出最後結果
- (5) 輸出 (全連接層)

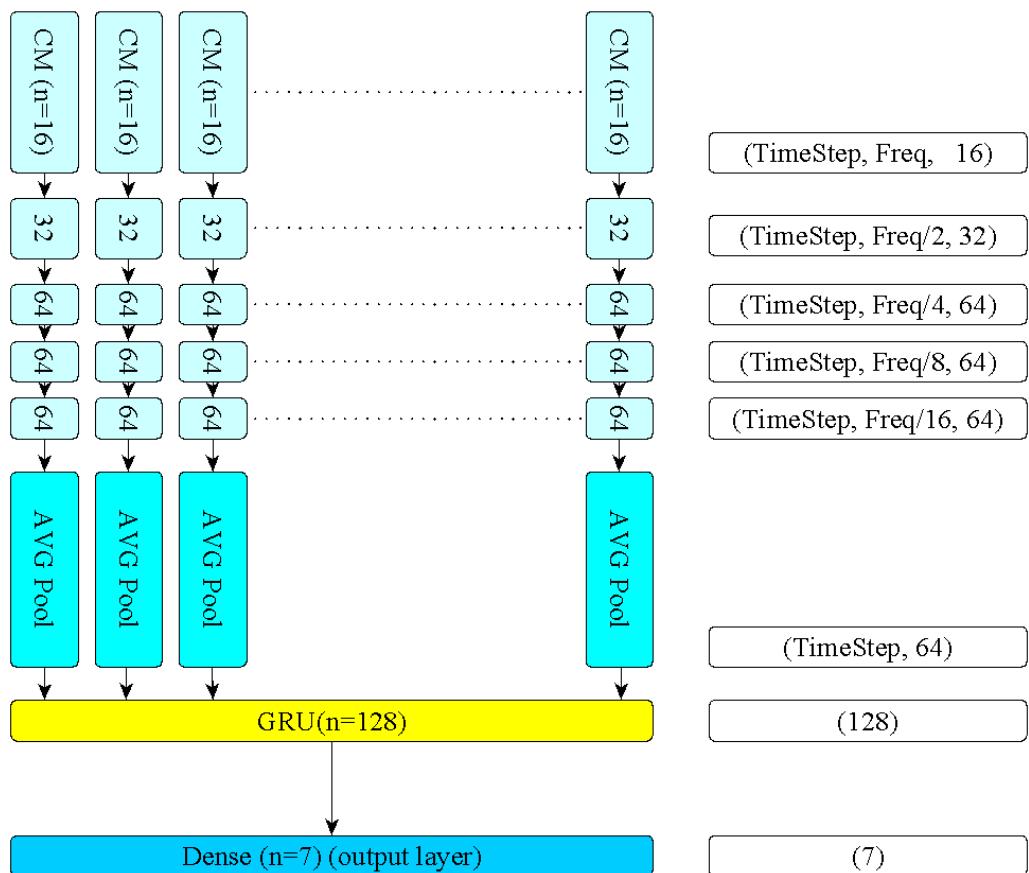


圖 13、以 GRU 為底之模型架構圖

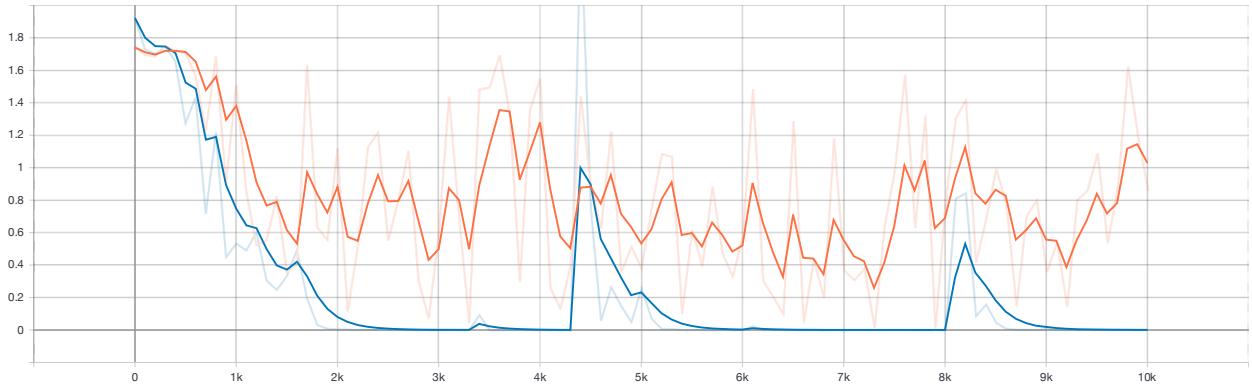


圖 14 (a)、Accuracy 變化 (橘色：測試資料；藍色：訓練資料)

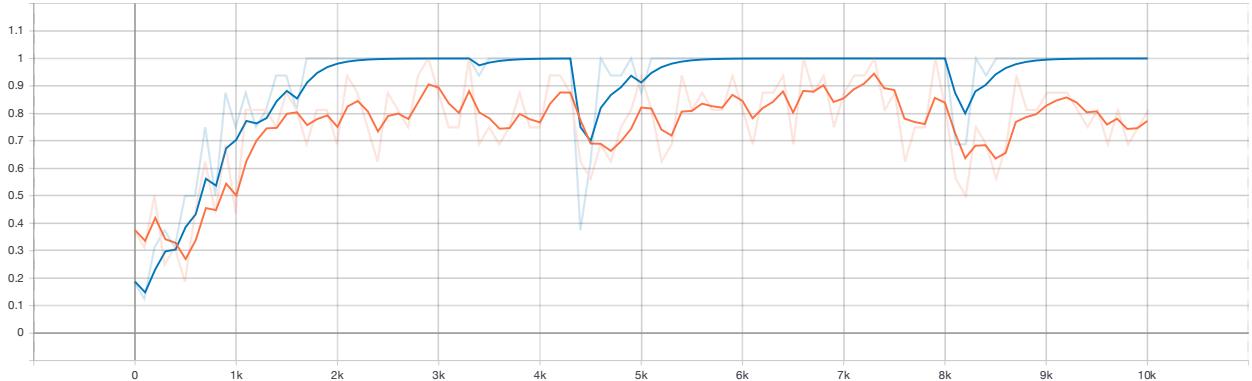


圖 14 (b)、Loss 值變化 (橘色：測試資料；藍色：訓練資料)

訓練的結果，最高能夠達到 85.20049%。

4. Attention

相較循環神經網路(Recurrent neural network)只能看到之前的資料，Self-attention 藉由平行運算可以一次看完所有內容並得出結果。模型架構如下：

- (1) 對於每一筆輸入，形狀為 (time step, freq, channels=1)
- (2) 在每個 time step 上做一維卷積以及 Max Pooling，減少 Freq 並增加 Channel
- (3) 在每個時間點平均池化，得到形狀 (time step, 1, channels=64)
- (4) 對每個時間點做 Attention
- (5) 對所有時間做平均池化
- (6) 輸出 (全連接層)

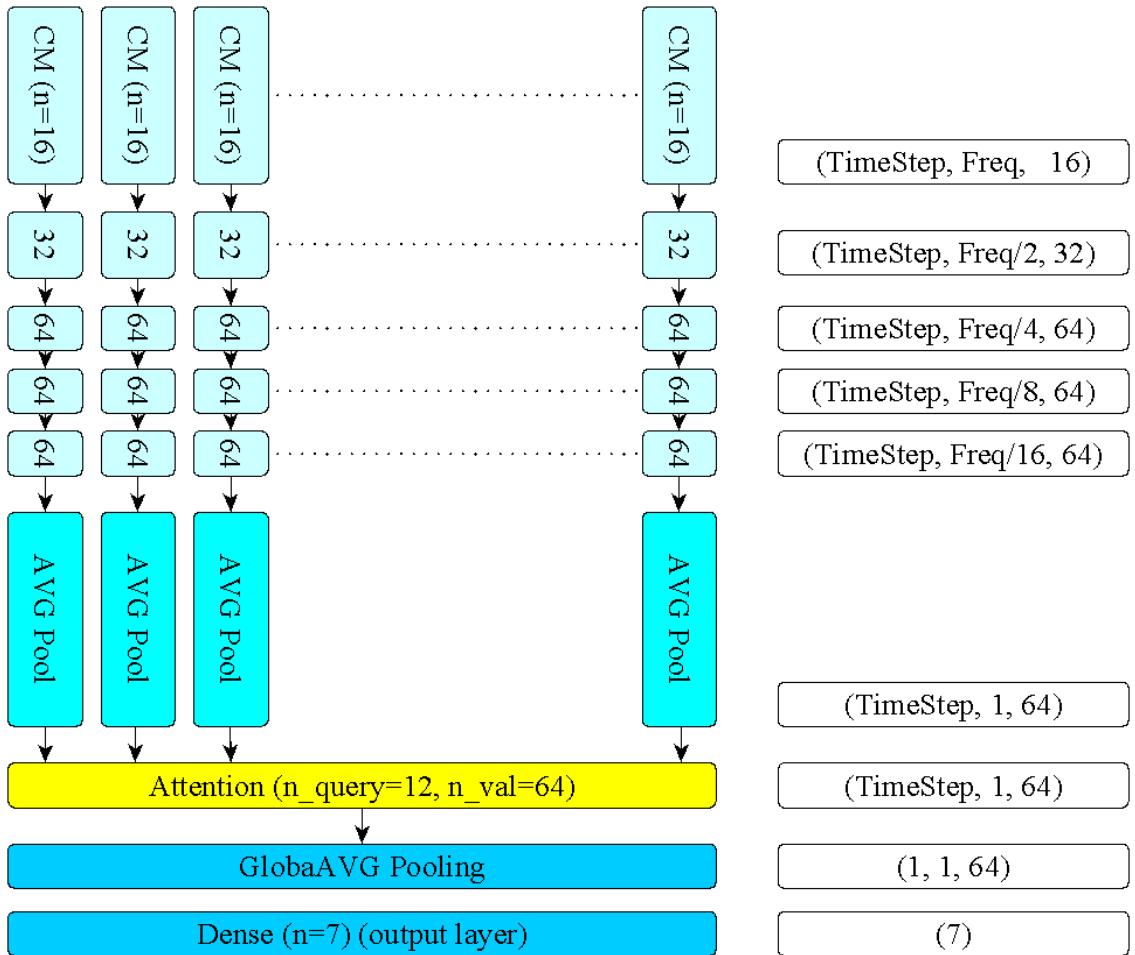


圖 15、以 Attention 為底之模型架構圖

```

144 [step: 0] Accuracy: 20.17937%, Best: 20.17937%
145 [step: 200] Accuracy: 63.67713%, Best: 63.67713%
146 [step: 400] Accuracy: 73.54260%, Best: 73.54260%
147 [step: 600] Accuracy: 83.85651%, Best: 83.85651%
148 [step: 800] Accuracy: 79.37220%, Best: 83.85651%
149 [step: 1000] Accuracy: 90.13453%, Best: 90.13453%
150 [step: 1200] Accuracy: 79.82063%, Best: 90.13453%
151 [step: 1400] Accuracy: 91.47982%, Best: 91.47982%
152 [step: 1600] Accuracy: 91.03139%, Best: 91.47982%
153 [step: 1800] Accuracy: 89.23767%, Best: 91.47982%
154 [step: 2000] Accuracy: 95.51569%, Best: 95.51569%
155 [step: 2200] Accuracy: 93.27354%, Best: 95.51569%
156 [step: 2400] Accuracy: 93.72197%, Best: 95.51569%
157 [step: 2600] Accuracy: 92.82511%, Best: 95.51569%
158 [step: 2800] Accuracy: 93.27354%, Best: 95.51569%
159 [step: 3000] Accuracy: 92.82511%, Best: 95.51569%

```

圖 16、實驗 log

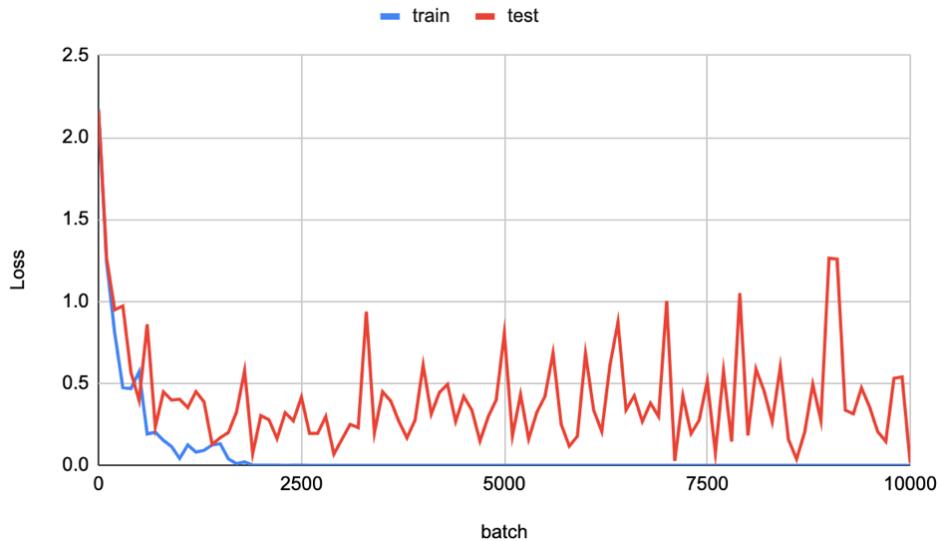


圖 17a、Accuracy 變化（橘色：測試資料；藍色：訓練資料）

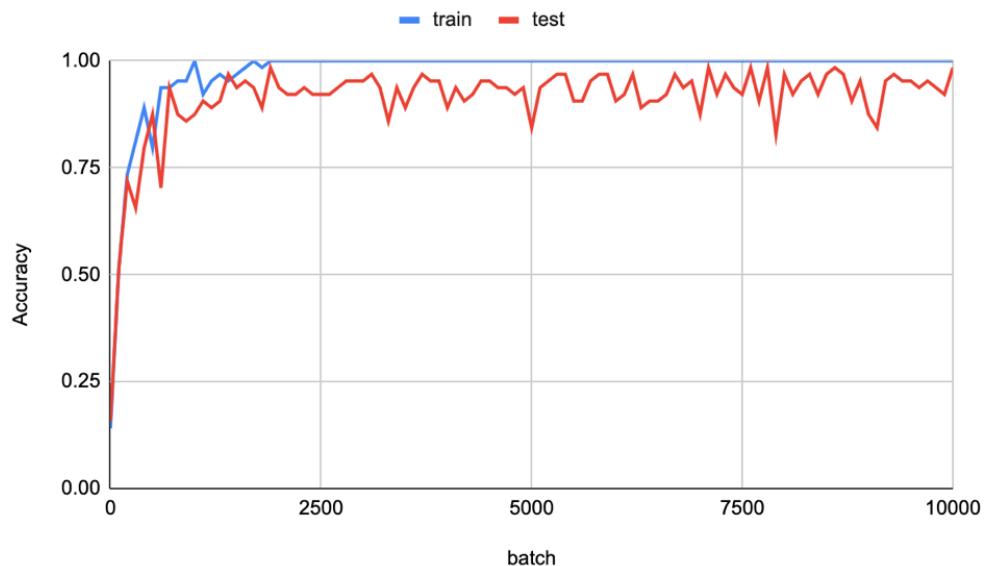


圖 17b、Loss 值變化（橘色：測試資料；藍色：訓練資料）

收斂速度極快，且測試資料準確度提高至 95.51569%。

伍、討論及應用

一、LSTM 實驗結果討論

- 藉由測試 Long short-term memory 模型後，可以知道利用 LSTM 訓練效果不盡理想：當模型太小時 loss 值無法收斂；模型太大時會因為資料集太小無法訓練太多 Node 導致 Overfitting。而藉由測試 Gated Recurrent Unit 模型後，可以發現經由 GRU 優化後可以有效減少所需 Node 大幅改善 Overfitting 的問題。

2. 藉由使用 Attention 之結果，將此技術套用到此問題獲得很大的改善。將其結果進行 Confusion Matrix 上可以發現每個時期之間都有很高的辨識率，唯獨產蛋期及育雛期有些相似，但就狀態上來看因為也是相近的；將訓練結果視覺化後，也可以看到分明顯的分塊現象。綜合以上結果，確定綠繡眼在不同時期的鳴叫聲的確有不一樣的特徵。

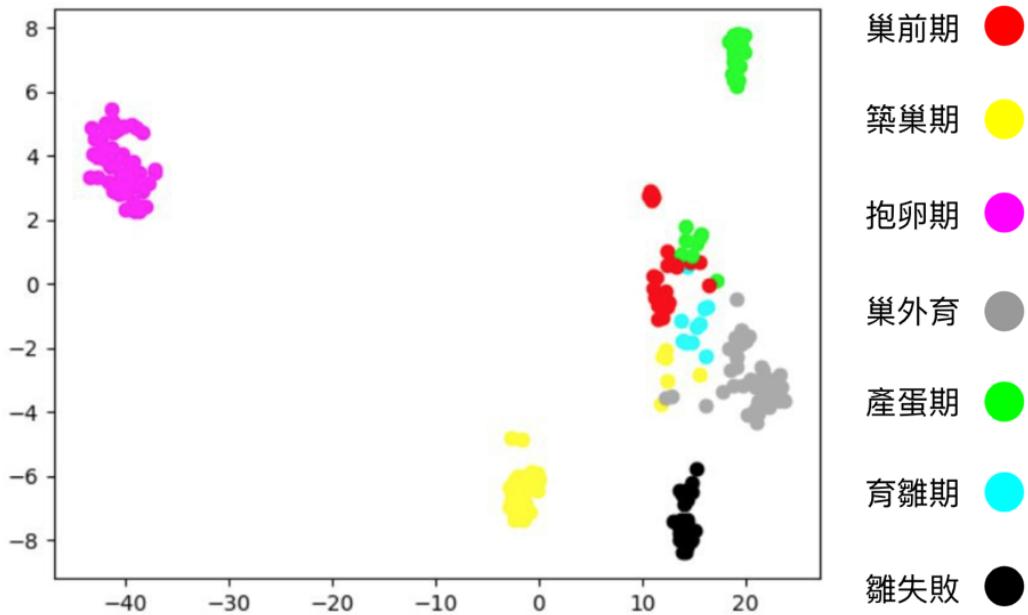


圖 18a、將訓練結果 t-SNE 降維視覺化之結果（二維）

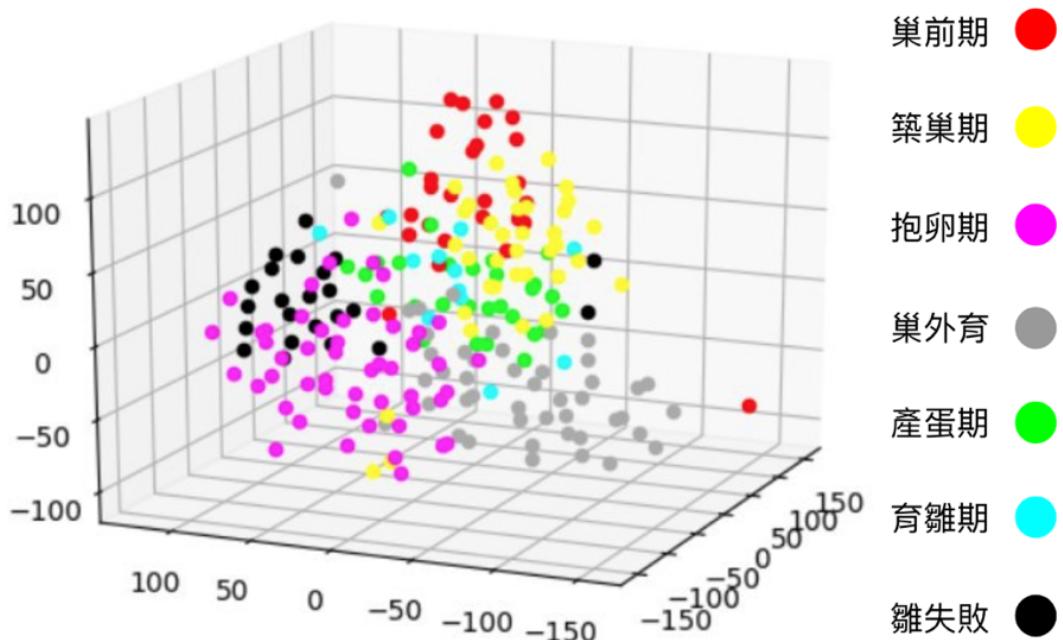


圖 18b、將訓練結果 t-SNE 降維視覺化之結果（三維）

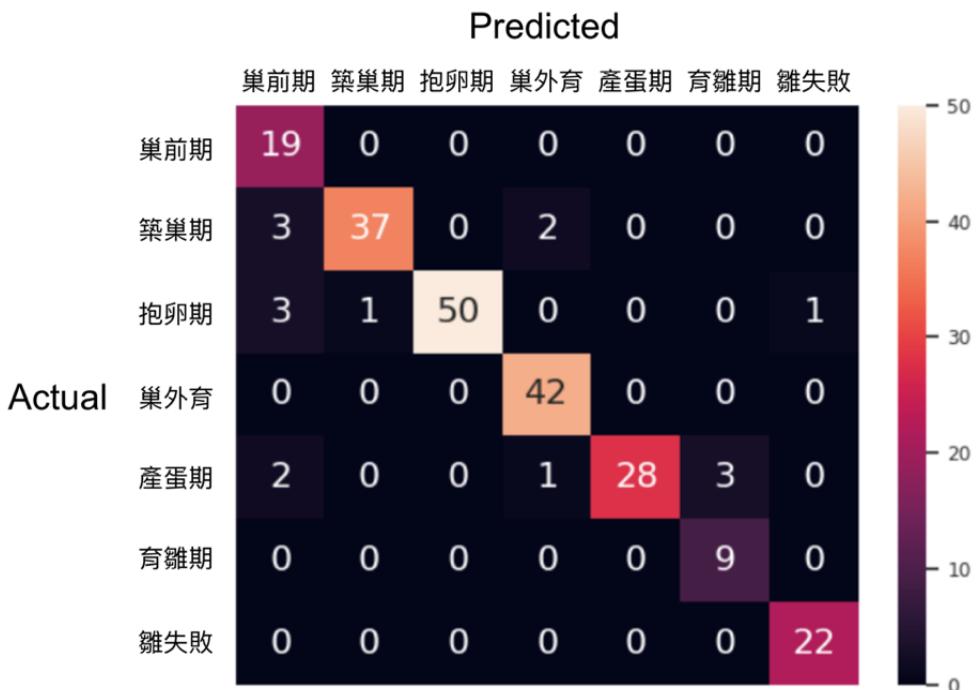


圖 19、使用 Attention 結構訓練結果之 Confusion Matrix

二、實驗誤差

1. 資料集大小

本次使用的資料集內容僅收錄綠繡眼鳴叫聲及其七種生活的時期之標籤，且已資料數量上看，若是要計算更加複雜的內容，勢必將不足以負荷。

2. 錄音品質

雖然經由改良後的模型已經有明顯進步，但以現在的資料集來說，只要是錄音效果不同都有可能會影響到實驗結果。未來訓練時應當於資料預處理時加入不同程度之雜訊，除了增加訓練資料集外也可以更接近實際應用情況。

3. 環境變因

如果將錄音地點移動到不同地形，亦或是使用不同的錄音設備，皆會影響到其正確率。因此如果訓練驗證資料各自取自不同來源，驗證之可信度會更高。

三、未來展望

1. 模型、資料集優化

在本次研究中，並沒有將資料集做特殊處理，或經由不同手續增加測試資料。除了從根本上增加資料集，在未來的研究也將把資料集做不同處理，讓控制變因增加，較能預期實驗效果；在研究模型上，也希望在未來能夠得到更高的訓練效果，因此也將測試不同的結構，讓成功率提升。

2. 比較不同物種之關係

因資料集的限制，本次研究僅能將視線限縮在綠繡眼的不同時期之鳴叫聲上，但我認為這種特徵不僅是在同一隻鳥的不同時期會有效果，不同物種之間說不定也會有相似的情況，甚至可以將兩相似之物種比較。希望未來可以比較各種鳥類於不同時期鳴叫聲之分別，並比較不同鳥類之間之相似度，藉此驗證不同鳥類之間的演化關係。

3. 建立親緣關係樹

除了應用在不同的物種之間外，我認為這種關係也有可能與個體和個體之間的親緣關係有所連結。如同聲紋一般，當兩個體之聲線、習慣越相同，除了可能生活在相同地點外，也有可能彼此有親緣關係。希望未來可以藉由更大量的資料及驗證此假說。

4. 聲音特徵符號化之可能性

雖然能夠初步發現各生理時期之特徵，但仍舊無法明確標示出各特徵出現的時間點或特徵內容。如果能夠找到某種方法表示所有鳴叫聲的發音規則，也就可以為每個聲音找到各自的符號，也就能反推不同符號代表的意思，也就能讓我們即使聽不懂也能夠藉由符號表推敲情緒及其意義。

陸、結論

- 一、綠繡眼於不同生理時期之鳴叫聲雖然以未受訓練之普通人無法分辨出區別，但藉由類神經網路得知，綠繡眼在不同時期之鳴叫聲可以依不同特徵被分辨出來。
- 二、藉由 Confusion Matrix 及 t-SNE 降維視覺化之結果，可以進一步藉由類神經網路證明綠繡眼於不同生理時期之鳴叫聲各具有不同特徵。
- 三、相較於 LSTM 及 GRU 之訓練模型，使用 Convolution Module 後配合 Attention 之模型能夠在短時間達到至少 95% 以上之分辨率，能夠有效藉由鳴叫聲辨識綠繡眼之生理時期。

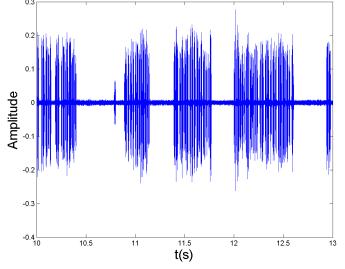
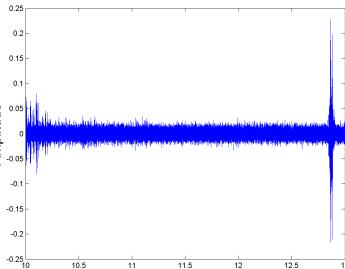
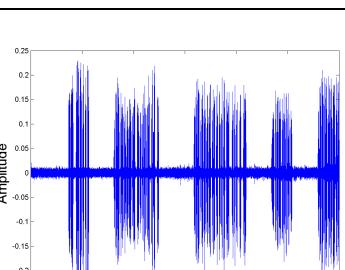
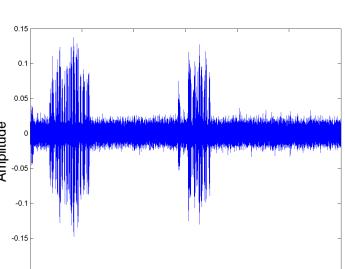
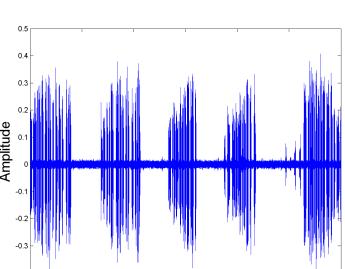
柒、參考資料

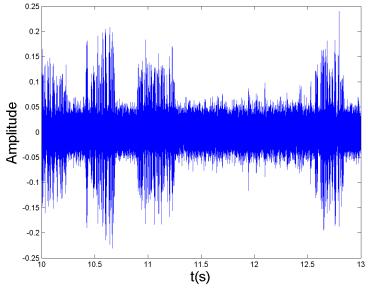
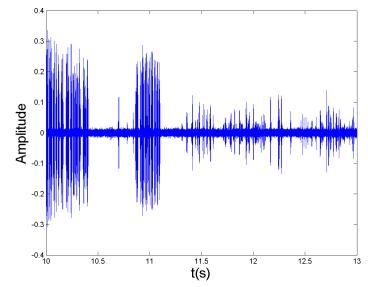
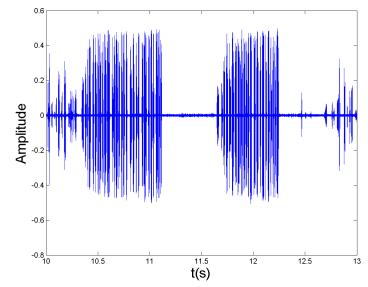
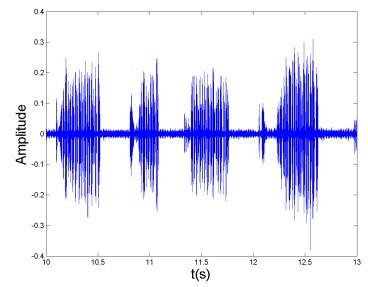
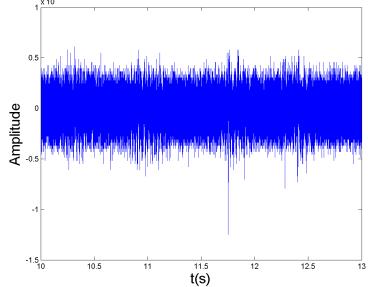
- [1] 取自 Wikipedia <https://zh.wikipedia.org/wiki/%E9%A0%98%E8%A7%92%E9%B4%9E>
- [2] 取自 TechNews <https://technews.tw/2019/08/22/ai-national-teams-get-new-contract-they-will-improve-taiwania-ii-computing-ability/>
- [3] 取自果凍博客 <https://www.guodong.net/?p=12549>
- [4] 齋藤康毅（2017）。Deep Learning 用 Python 進行深度學習的基礎理論實作。台北市碁峰資訊。
- [5] Ashish Vaswani Noam Shazeer Niki Parmar Jakob Uszkoreit Llion Jones Aidan N. Gomez Lukasz Kaiser Illia Polosukhin. NIPS (2017) . Attention Is All You Need.
- [6] 林育德、郭鈴莉、劉宗憲、崔致豪。語音辨識 Speech Recognition (MFCC 應用)。逢甲大學自動控制工程學系。
- [7] Brandon Rohrer, Jimmy Lin (May 25, 2017) . Data Science and Robots.
From <https://brohrer.mcknote.com/zh-Hant>
- [8] Airwaves (Sep 5, 2018) . 使用 TensorFlow 了解 Dropout.
From <https://medium.com/手寫筆記/使用-tensorflow-了解-dropout-bf64a6785431> .
- [9] TengYuan Chang (Feb 17, 2019) . 比較長短期記憶模型 (LSTM) 與改良後的遞歸神經網路模型：GRU. From <https://link.medium.com/tXL6ht36H6> .
- [10] Kun Li (Mar 3, 2018) . 圖像分類中 max-pooling 和 average-pooling 之間的異同. From <https://blog.csdn.net/u012193416/article/details/79432668> .
- [11] GGWithRabitLIFE (Aug 5, 2018) . SGD, Momentum, AdaGrad, Adam Optimizer. From <https://link.medium.com/uj8T60BFP6>
- [12] Ryan Lu (Apr 1, 2019) . Learning Model : Gradient Descent -Learning Rate Schedules 和深度學習的學習率學習方法. From <https://link.medium.com/jnCoWPYGP6>
- [13] Mike Smales (Feb 27, 2019) . Sound Classification using Deep Learning. From <https://link.medium.com/zQPNqbeMI6>
- [14] 江郁宣（2010）。從發音結構與 DNA 序列探究擬金眼鯛科(Pempheridae)之親緣關係。國立中山大學海洋生物研究所。
- [15] 林威廷。塔米爾文語音辨識系統之設計研究。資訊科技國際期刊第八卷第一期第 60~69 頁。

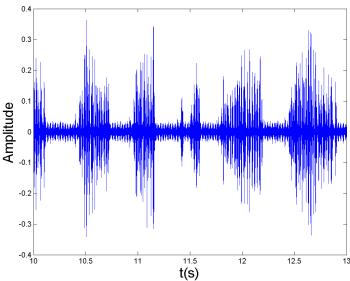
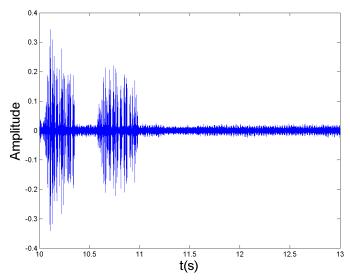
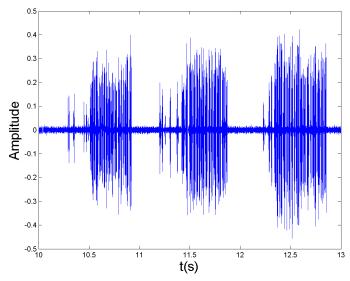
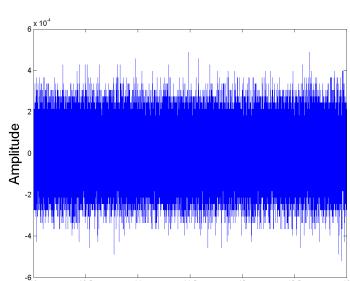
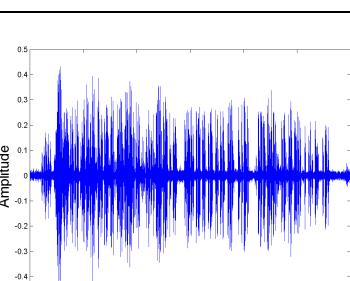
捌、附件

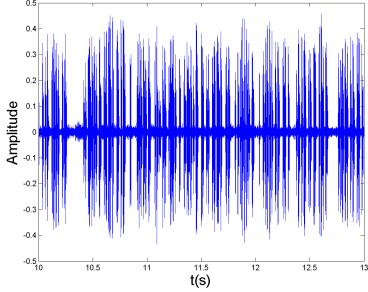
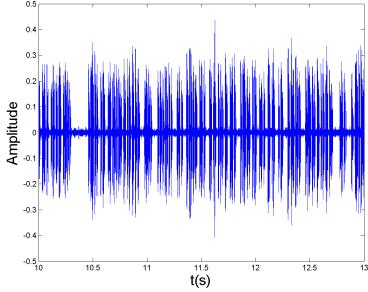
一、所有原始資料之預覽（波形圖僅顯示約前 13 秒）

日期	天氣	鳴者	生殖階段	波形圖
2001/4/3	陰時雨	右 B.W 左 O	抱卵期	
2001/4/6	晴	右 BW 左 O	抱卵期	
2001/4/9	陰	右 BW 左 O	育雛期	
2001/5/28	雲	右 BW 左 O	育雛期	
2001/4/10	晴	右 BL 左 R	巢前期	

2001/5/5	陰	右 BL 左 R	抱卵期	
2001/7/2	晴	右 BL 左 R	下第 2 蛋	
2001/7/4	雲	右 BL 左 R	抱卵期	
2001/7/7	晴	右 BL 左 R	抱卵期	
2001/7/13	晴	右 BL 左 R	育雛期	

2001/7/17	晴	右 BL 左 R	育雛期	
2001/7/20	陰	右 BL 左 R	育雛期	
2001/5/3	陰	右 DGLBL 左 BL	築巣期	
2001/5/9	陰雨	右 DGLBL 左 BL	下第 2 蛋	
2001/7/1	晴	右 OB 左 W	抱卵期	

2001/7/2	晴	右 OB 左 W	抱卵期	
2001/7/4	雲	右 OB 左 W	抱卵期	
2001/7/7	晴	右 OB 左 W	抱卵期	
2010/4/22	陰時雨	右 OG	巢前期	
2010/4/27	霧	右 OG	築巢期	

2010/5/17	雲	右 OG	抱卵期	
1999/5/19	陰	右 OG	抱卵期	
1999/5/31	陰	右 OG	育雛期	